

**SETEMBRO
2025****01****Existe uma meia-vida para as taxas de sucesso dos agentes de IA?**

Um estudo revela que agentes de IA apresentam um padrão previsível de queda de desempenho conforme as tarefas se tornam mais longas e complexas.

02

pág.

02**Como a IA impulsiona a originalidade da arte humana**

À medida que a inteligência artificial avança na criação artística, artistas são desafiados a explorar novas formas de criatividade, espontaneidade e expressão genuinamente humana.

03

pág.

03**O problema das LLMs e a Torre de Hanoi**

Mesmo com avanços em raciocínio lógico, pesquisas mostram que LLMs ainda enfrentam dificuldades para executar etapas simples de forma consistente em problemas complexos como a Torre de Hanoi.

04

pág.

Existe uma meia-vida para as taxas de sucesso dos agentes de IA?

Texto por Gustavo Neves Moraes

Um time de pesquisadores do METR propuseram um modelo matemático para explicar um fenômeno recorrente: o desempenho decrescente de agentes de IA conforme a duração das tarefas aumenta.

Objeto de Estudo

Ao submeter diferentes modelos de IA a tarefas mais longas (em termos de tempo que um ser humano levaria para realizar), os pesquisadores perceberam que o desempenho das IAs cai de forma previsível. Essa queda segue um padrão matemático conhecido: o modelo de taxa de risco constante, bastante usado em análises de sobrevivência, como no decaimento radioativo – por isso o termo “meia-vida”.

A lógica por trás da queda

Tarefas mais longas geralmente envolvem várias subtarefas em sequência. Se a IA tem uma chance constante de falhar em cada etapa, a probabilidade de sucesso no total da tarefa cai exponencialmente conforme o aumento do número de etapas.

$$Pr(Task) = \prod_{i=1}^n Pr(SubTask_i) = Pr(SubTask_1) * Pr(SubTask_2) * \dots * Pr(SubTask_n)$$

Assim como na meia-vida de um elemento radioativo, podemos falar que uma “meia-vida de sucesso” para a IA seria o tempo (em termos de tempo humano) até que a chance de sucesso caia para 50%.

Exemplo prático

No caso do modelo Claude 3.7 Sonnet:

- Consegue manter 50% de sucesso em tarefas de até 59 minutos.

- Mas se quisermos uma taxa de sucesso de 80%, o limite de duração cai para apenas 15 minutos.
- Esse comportamento segue a previsão teórica de que o tempo para 80% de sucesso é cerca de 1/3 do tempo para 50

Previsão futura: Quanto tempo até melhorar?

Se assumirmos que o desempenho desses agentes dobra a cada 7 meses, como sugerem os dados, o estudo estima que:

- Para ir de 50% para 80% de sucesso em uma mesma tarefa, levará cerca de 1 ano.
- Para alcançar 90%, cerca de 2 anos.
- Para 99%, 4 anos.
- Para 99,9%, 6 anos.

Levar o pensamento humano

Curiosamente, os humanos parecem lidar melhor com tarefas prolongadas. Mesmo em tarefas com duração de 12 horas, humanos ainda apresentaram mais de 20% de sucesso, contra os 6,25% previstos pelo modelo exponencial.

Isso pode estar relacionado com a capacidade humana de corrigir erros durante o processo ou porque há uma variação natural de desempenho entre pessoas (efeito de mistura populacional). No entanto, levar isso como modelo de comparação revela algumas limitações e críticas.

Limitações e críticas

- Existe um debate sobre o que significa “tempo de tarefa” quando comparado ao tempo que um humano levaria e o de uma IA, pois existem tarefas que os humanos consistentemente se saem melhor e o contrário também acontece.
- O modelo de taxa de risco constante é uma aproximação. Ele serve como linha de base teórica, mas ainda faltam dados sobre como a taxa de risco realmente evolui ao longo do tempo para diferentes modelos.

Conclusão



O estudo ajuda a quantificar um problema real e fornece um primeiro modelo matemático para discutir o tema, a ideia de uma “meia-vida de sucesso” para IAs traz uma analogia poderosa para pensar o desempenho ao longo do tempo. Ou seja, mesmo se forem encontrados desvios sistemáticos do decaimento exponencial, como o aumento (ou a diminuição) da taxa de risco com o tempo, isso poderá fornecer dicas úteis sobre o que os agentes estão fazendo de errado (ou certo). Ou seja, o modelo de taxa de risco constante também pode funcionar como uma linha de base teórica a partir da qual se medem os desvios empíricos.

O que é possível aprender?

- IA ainda é pouco confiável em tarefas longas e complexas, mesmo que seja boa em tarefas curtas.
- A forma de medir performance ao longo do tempo (com um conceito simples como “half-life”) pode ajudar muito a comparar modelos.
- Essa métrica abre espaço para novas formas de avaliar a evolução da IA ao longo dos meses, com foco na durabilidade da performance.
- Pode ser uma boa inspiração para como medir robustez em nossos próprios projetos de IA.

Gostou do texto?

Leia também a fonte original aqui.


Como a IA impulsiona a originalidade da arte humana

Texto por Sabrina Cristan

Nos últimos anos, as limitações da inteligência artificial vêm diminuindo rapidamente. Hoje, a reprodução de pinturas e fotografias por esses modelos pode ser quase indistinguível da criação artística humana. Um trabalho manual que levaria horas de dedicação para ser finalizado, poderia ser gerado por IA em pouquíssimo tempo. Essa constatação leva à uma reflexão essencial: o que torna a arte humana algo verdadeiramente único?



Legenda: Paisagem fotografada por Alvin Greis.



Legenda: Fotografia gerada por IA.

Espontaneidade como essência

A resposta parece estar na espontaneidade. Por mais poderosa que seja, a IA opera com base em previsões, e o imprevisível escapa ao olhar de qualquer algoritmo. Se uma imagem, mesmo que complexa, pode ser reproduzida por tal tecnologia, significa que a sua composição não é, afinal, tão original assim, pois pode ser reduzida a uma “fórmula”.

Nesse sentido, artistas podem sentir desconforto ao terem a autenticidade dos seus trabalhos verificada por IAs, como se eles estivessem sendo, aos poucos, substituídos por um criador mais rápido e preciso.

Parceria criativa

Por outra perspectiva, sem o avanço da inteligência artificial, o rigor artístico poderia não evoluir tanto. As IAs podem permitir que artistas se reinventem, capturam de forma ainda mais apurada a essência humana em suas obras, fujam do óbvio e criem algo extraordinariamente singular, desafiando, ou até mesmo

unindo-se, às alternativas que a inteligência artificial traz ao mundo artístico.



Legenda: O píer, os carros, as árvores, todos sustentam a fotografia em sua essência. Mas o gesto intencional da câmera abre uma fratura na própria realidade. Algo que os algoritmos ainda não sabem repetir.

Nesse sentido, vale mencionar a artista Holly Herndon que, ao lado do seu parceiro Mathew Dryhurst, explora as possibilidades de intersecção entre arte e machine learning, principalmente através da música, onde a inteligência artificial tem um papel fundamental como parceira criativa. Herndon treinou um modelo de machine learning com uma vasta variedade de fonemas da língua inglesa, com o intuito de possibilitar que o seu software, batizado de Holly+, pudesse reproduzir muitos sons diferentes. Após esse treinamento, a artista conseguiu mapear sua voz para outros idiomas e atingir tons além da capacidade física da voz da Holly humana. Atualmente, ela utiliza essa ferramenta em suas performances musicais.

Conclusão

Apesar dos avanços, ainda há muitas criações que não podem ser reproduzidas, pois não foram rotuladas nem transformadas em dados para alimentar um algoritmo. Além disso, com tantos avanços tecnológicos, as possibilidades da arte são reafirmadas e, de inimiga, a tecnologia surge como uma aliada. E é justamente aí que reside a verdadeira "beleza" da IA: uma ferramenta que incentiva as pessoas a se arriscarem mais e a se embriagarem de criatividade, capacidade humana que nenhum algoritmo poderia replicar tão bem.

Gostou do texto?

Leia também a fonte original aqui.

Outras fontes:

- Sp-arteSP-Arte
- NprHolly Herndon: How AI can transform your voice

O problema das LLMs e a Torre de Hanoi

Texto por Hugo Cardoso

Nos últimos anos, os modelos de linguagem, conhecidos como LLMs, evoluíram bastante. Antes, eles apenas geravam textos com base no que foi treinado. Agora, parecem até capazes de pensar de forma lógica e resolver problemas mais complexos. Com a chegada dos chamados LRMs, que são modelos pensados para "raciocinar", como o Claude Thinking, Gemini Thinking e DeepSeek-R1, muita gente começou a acreditar que estávamos mais perto de criar uma inteligência artificial realmente inteligente, parecida com a humana. Esses novos modelos funcionam de um jeito diferente: antes de responder, eles pensam em etapas. Isso é chamado de Chain-of-Thought, ou "cadeia de pensamento". A ideia é que, ao pensar passo a passo, eles consigam chegar a soluções melhores. Um estudo chamado The Illusion of Thinking, feito por pesquisadores da Apple, tentou responder essa pergunta. Para isso, eles usaram problemas controlados, como o clássico quebra-cabeça da Torre de Hanoi. Nesse jogo, é preciso mover discos de um pino para outro, seguindo regras simples: só dá para mover um disco por vez, e nunca se pode colocar um disco maior em cima de um menor. Parece simples, mas o número de movimentos necessários cresce rápido conforme a quantidade de discos aumenta.

O colapso dos modelos de LRM e LLMs

Foi justamente aí que os pesquisadores perceberam algo curioso. Quando a dificuldade do problema aumenta, os modelos que pareciam tão bons simplesmente param de funcionar. Mesmo com bastante espaço para gerar respostas (o chamado limite de tokens), os LRMs e LLMs não conseguem mais resolver o problema. Eles travam, ou pior, fazem movimentos errados. Outro achado marcante

é que, mesmo quando os pesquisadores fornecem o algoritmo correto da Torre de Hanoi no prompt, esperando que o modelo apenas execute os passos, o colapso ainda acontece. Isso indica que o problema não está apenas na dificuldade de encontrar uma solução, mas também em seguir instruções lógicas de forma consistente, algo que seres humanos fariam com facilidade, especialmente se o algoritmo estivesse dado.

E tem mais:

Mesmo quando os cientistas dão o passo a passo certo para resolver a Torre de Hanoi, esperando que o modelo apenas siga as instruções, o erro continua. Ou seja, o problema não está só em descobrir a resposta, mas também em executar uma sequência de instru-

ções simples, o que qualquer pessoa com o algoritmo na mão conseguiria fazer. Esses resultados colocam em xeque a ideia de que os LLMs atuais são capazes de raciocínio generalizável. Embora suas respostas possam parecer “inteligentes”, sua capacidade real de executar passos lógicos, planejar e resolver problemas de forma sistemática ainda é extremamente limitada.

Gostou do texto?

Leia também a fonte original aqui.



Editores: Nome 1, Nome 2, ..., Nome n.